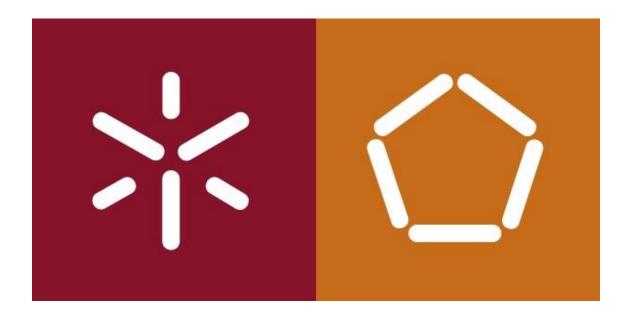
## Universidade do Minho

Departamento de Informática Mestrado Integrado em Engenharia Informática



Perfil de Machine Learning: Fundamentos e Aplicações Classificadores e Sistemas Conexionistas Trabalho Prático nº 5

> Ricardo Pereira (A77045) 26 de março de 2020

## Parte 1

No primeiro exercício desta ficha era pretendido que fosse implementada uma rede LSTM com o objetivo de compreender a forma como se comportam estas redes. Foi observado através de múltiplas execuções, variando o número de épocas, timesteps e features, a performance que este tipo de redes recorrentes apresentam. Tratando-se o problema em questão de tentar fazer com a rede prevê-se números aleatórios com base no conhecimento de escolhas de números aleatórios em sequência, as execuções feitas demonstram alguma instabilidade de resultados como seria de prever pois tratando de sequências aleatórias tornam-se também imprevisíveis. Deixo aqui apenas um log de uma das execuções:

timesteps = 10 features = 25

Utilizando estes valores para timesteps e features obtiveram-se os seguintes resultados:

```
PS C:\Users\Bosch\Desktop\Mestrado\MifA\Z\P \text{ Semestre\CSC\TPS} & C:\Users\Bosch\Amazonda3\envs\CSC\python.exe "C:\Users\Bosch\Desktop\Mestrado\MifA\Z\P \text{ Semestre\CSC\TPS\CSC\Lambda}." Semestre\CSC\TPS\CSC\Lambda}.

22020-03-22 2215:44.663465:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64 101.dll
22020-03-22 2215:44.663465:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library nevuda.dll
22020-03-22 2215:46.66368:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library nevuda.dll
22020-03-25 2215:46.66368:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64_101.dll
22020-03-25 2215:46.763791:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64_101.dll
22020-03-25 2215:46.763791:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64_101.dll
22020-03-25 2215:46.763791:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64_10.dll
22020-03-25 2215:46.763761:1 tensorflow\stream_executor\platform\default\dso_loader.cc:44\Boxecsfully opened dynamic library cudart64_1
```

```
Total params: 134,297
Trainable params: 134,297
Non-trainable params: 0

None
2020-03-25 22:15:51.455039: I tensorflow/stream_executor/platform/2020-03-25 22:15:51.779204: I tensorflow/stream_executor/platform/Epoch: 0; Loss: 16.12; Accuracy: 0.00
Epoch: 1; Loss: 1.27; Accuracy: 0.00
Epoch: 2; Loss: 1.61; Accuracy: 0.00
```

```
Epoch: 98; Loss: 16.12; Accuracy: 0.00
Epoch: 99; Loss: 16.12; Accuracy: 0.00
Accuracy: 6.00
Sequence: [[18, 8, 13, 21, 19, 9, 18, 8, 6, 22]]
Expected: [13]
Predicted: [2]
```

## Parte 2

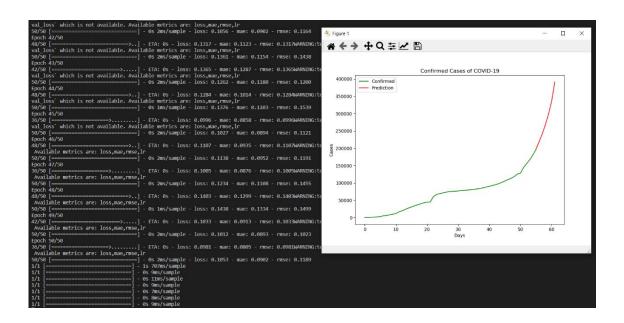
Neste segundo exercício era pretendido que fosse criada uma rede MLP ou LSTM para prever o número de casos confirmados esperados nos próximos 7 dias de COVID-19. Foi então criada uma rede LSTM e o processo foi o seguinte:

- Começar por importar e preparar o dataset dos casos confirmados até ao momento;
- Construir uma rede LSTM através da api Keras, utilizando um modelo sequencial de várias camadas incluindo, para além de LSTM's, Dense. Para função de cálculo de Loss foi utilizada a função root mean square error construída através do uso de funções disponibilizadas pela api Keras;
- Por fim, foi criada a função forecast que efetua as previsões e outra função para demonstrar o gráfico obtido de casos confirmados nos próximos 7 dias.

Nas imagens podemos ver uma das execuções efetuadas, vendo o gráfico de casos confirmados previsto a vermelho e a verde os do dataset:

```
PS C: Users \Bosch\Desktop\Westrado\MIFA\2e Semestre\CSC\TPS\EXCS & C:/Users\Bosch\Anaconda3/envs/CSC/python.eve "c:/Users\Bosch\Desktop\Mestrado\MIFA\2e Semestre\CSC\TPS\EXCS\CSC\Python.eve "c:/Users\Bosch\Desktop\Mestrado\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mestrado\MIFA\2e Semestre\CSC\TPS\Excs\Bosch\Desktop\Mestrado\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mestrado\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mestrado\MIFA\2e Semestre\Csc\Python.eve "c:/Users\Bosch\Desktop\Mestrado\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mestrado\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mifa\Accord\Csc\Python.eve "c:/Users\Bosch\Desktop\Mifa\Accord\Csc\Python.e
```

```
Model: "sequential
Layer (type)
        Output Shape
lstm (LSTM)
               16896
lstm_1 (LSTM)
        (None, 5, 128)
               98816
lstm_2 (LSTM)
        (None, 256)
dense (Dense)
        (None, 64)
               16448
dropout (Dropout)
        (None, 64)
dense_1 (Dense)
        (None, 1)
               65
Train on 50 samples
Epoch 1/50
```



Como se pode ver todo os objetivos desta ficha foram alcançados, com a compreensão das redes recorrentes, mais propriamente com a utilização das mesmas através de LSTM disponibilizadas pela api Keras.

Na imagem seguinte podemos ver o modelo que foi construído mais detalhadamente:

